Note technique

Tarification de l'assurance automobile

Étude réalisée par : Morel POUNIGUIA

Objet et données

Cette note présente la démarche et les résultats de l'analyse des trois bases fournies : sinistres, portefeuille et expositions (années 2009 et 2010). Elle s'appuie sur le notebook `analyse_resultats.ipynb`, dont chaque étape reprend le code, les graphiques et les points clés. Le portefeuille consolidé compte **100 000 polices**, dont **87,7 %** n'ont aucun sinistre sur la période.

Audit et nettoyage

L'audit relève des valeurs impossibles (âges de 4 à 250 ans, ancienneté négative), 55 doublons stricts, 146 numéros de police répétés et des codes non normalisés (« ?? », « NA », sexe codé « Male/H/h »). La variable `SubGroup2` est renseignée à 11,6 % seulement : elle n'est pas utilisée comme variable explicative. L'incohérence « Housewife » pour un conducteur masculin touche **12,7 %** des lignes : il s'agit probablement d'un problème de codage. Ces lignes sont conservées, signalées, et `Occupation` reste dans le tarif, avec une surveillance au recalibrage.

Le nettoyage documente 25 décisions et ne retire que 0,09 % des sinistres. Il corrige davantage qu'il ne supprime, ce qui préserve l'exposition. Après nettoyage, tous les contrôles de cohérence passent.

Jointures

La jointure du portefeuille avec l'exposition est 1 à 1, sans doublon. Les sinistres se joignent aux polices en n à 1 : **1 011 lignes** (945 numéros de police, soit 7,6 % des sinistres) n'ont pas de police correspondante et sont exclues de la tarification. Si ces contrats existent réellement, la fréquence et la prime pure sont sous-estimées d'autant. Ce point doit être signalé au gestionnaire des données.

Analyse descriptive

Le nombre de sinistres est surdispersé : le rapport variance/moyenne vaut 1,30 et le test de Cameron-Trivedi est très significatif. La binomiale négative décrit mieux que la loi de Poisson les polices multi-sinistrées. Le montant d'un sinistre a une queue épaisse : moyenne 1 174 €, médiane 617 €, P99 de 8 621 €. La loi Gamma ajuste mieux que la log-normale (écart d'AIC de 173 points).

Les écarts de prime pure bruts les plus forts concernent la tranche d'âge (×5,6) et l'occupation (×4,7). Le test du khi-deux relie les six variables qualitatives à la survenance, mais les V de Cramér restent faibles (0,02 à 0,18). Une variable seule ne suffit donc pas : c'est la combinaison des facteurs qui compte.

Segmentation

L'ACP ne résume que 44,5 % de l'information sur les deux premiers axes, car les variables sont peu corrélées entre elles. La classification (k-moyennes et hiérarchique) donne un accord modéré (ARI = 0,36) et une silhouette faible (0,18) : le portefeuille forme un *continuum de risque* plutôt que des classes nettes. Les profils servent à décrire le portefeuille, non à tarifer (tableau 1).

Profil	Polices (%)	Fréquence (pour 100 ans)
Faible risque	41,1	8,1
Risque élevé	30,4	33,2

Tableau 1. Deux profils extrêmes de la segmentation.

Le profil à risque élevé a une fréquence 4,1 fois supérieure au profil faible.

Modélisation

La fréquence est modélisée par un GLM de Poisson, une forêt aléatoire et un gradient boosting de Poisson. Le coût par sinistre est modélisé par un GLM Gamma. Les modèles sont évalués sur un jeu de test, à partir d'un tirage aléatoire à graine fixe (tableau 2).

Modèle de fréquence	Déviance de test	Gain vs constante	Surapprentissage (%)
Constante (référence)	0,710	–	–
GLM de Poisson	0,566	20,3 %	1,4
Gradient boosting de Poisson	**0,552**	**22,3 %**	7,9

Tableau 2. Comparaison des modèles de fréquence sur le jeu de test.

Le gradient boosting est le plus précis, mais le GLM obtient plus de 90 % de son gain avec une lecture beaucoup plus simple, ce qui le rend plus facile à justifier auprès du régulateur et des réseaux commerciaux. Le GLM sert donc de base au tarif, et le boosting de référence de performance. Le modèle de fréquence est bien calibré (prédit/observé = 1,008) et sépare bien les risques (indice de Gini de 0,52). Pour le coût, le gain n'est que de 4,6 % : le montant d'un sinistre dépend surtout des circonstances, et la tarification repose donc principalement sur la fréquence.

Tarification et prévision 2010

Le tarif est construit sur 2009 et testé sur 2010. Les facteurs les plus discriminants sont le bonus-malus, l'âge et la densité de la zone (tableau 3). Certaines modalités ont des effets de sens contraire entre fréquence et coût : les retraités ont moins de sinistres mais plus coûteux. Modéliser séparément fréquence et coût rend ces mécanismes visibles.

Facteur tarifaire	Écart de prime (plus cher / moins cher)	Rang
Bonus-malus	×4,05	1
Âge	×3,46	2
Densité de la zone	×2,97	3
Profession	×2,00	4
Ancienneté du contrat	×1,37	5
Type de véhicule	×1,19	6

Tableau 3. Écart de prime entre la modalité la plus chère et la moins chère, par facteur.

La sinistralité a augmenté en 2010 : la fréquence passe de 15,6 à 17,2 pour 100 ans et le coût moyen de 702 € à 736 €. Le coût 2010 prévu par le tarif 2009 est inférieur de 12,4 % au coût observé. Un **coefficient de tendance de 1,154** est donc nécessaire, à confirmer sur davantage d'historique puisqu'il ne repose que sur deux années.

Un tarif uniforme provoque de l'antisélection : le ratio sinistres/primes va de 0,23 (décile 1) à 4,22 (décile 10). Avec le tarif segmenté, il reste entre 1,09 et 1,25 et l'écart est homogène d'un décile à l'autre : la segmentation reste valable d'une année sur l'autre, seul le niveau général doit être ajusté. La prime commerciale médiane est de 86 €, et 90 % des assurés paient entre 26 € et 470 €.

Limites

Les points suivants limitent la portée des résultats :

- deux années seulement : la hausse de 2010 peut être durable ou ponctuelle ;
- les sinistres sans police (7,6 %) et l'incohérence de `Occupation` peuvent biaiser les estimations ;
- avec 100 000 polices, presque tous les tests sont significatifs : la taille des effets compte davantage que les p-valeurs ;
- la surdispersion rend les intervalles de confiance du GLM de Poisson un peu trop étroits ;
- le chargement de 30 % est une hypothèse, à remplacer par les frais réels.

Recommandations

Les recommandations sont classées par priorité. Chacune précise le constat qui la justifie, l'action proposée et l'indicateur de suivi.

Avant la mise en production

1. **Retrouver les sinistres sans police** (7,6 %) : les rapprocher du système de gestion, réintégrer ceux qui sont retrouvés et recalculer le tarif. *Suivi* : part de ces sinistres, cible proche de 0 %.
2. **Fiabiliser les données à la source** : clés uniques, bornes d'âge et d'ancienneté, codes fermés, contrôles bloquants à la saisie. *Suivi* : nombre d'anomalies par contrôle.
3. **Clarifier le codage de la profession** (12,7 % de « Housewife » pour des hommes ; 1 734 « Retired » de moins de 50 ans) : vérifier la définition auprès du gestionnaire, puis recoder. *Suivi* : stabilité des coefficients à chaque recalibrage.

Construction du tarif

4. **Tarifer avec le GLM, piloter avec le gradient boosting** : le GLM obtient 94 % du gain du boosting et reste explicable. Le boosting sert à repérer les segments mal tarifés. Le sexe reste exclu du tarif. *Suivi* : indice de Gini (0,52) et rapport prédit/observé par groupe.
5. **Ajouter la zone géographique au GLM tarifaire** : elle est la 4e variable la plus utile au modèle de fréquence (6 % de déviance), alors que la grille n'utilise que la densité. Vérifier la redondance avec la densité. *Suivi* : gain de déviance sur le test.
6. **Écrêter les gros sinistres** : plafonner chaque sinistre au P99 (environ 8 600 €) et répartir le surcoût ; couvrir le reste en réassurance en excédent de sinistre. La loi Gamma sous-estime le P99 de 28 %.
7. **Revoir le chargement et fixer une prime minimale** : un chargement proportionnel de 30 % laisse un retraité à fort bonus à 19 € par an, probablement insuffisant pour les frais. Remplacer par un montant fixe plus un pourcentage, calé sur les frais réels. *Suivi* : ratio combiné par décile.
8. **Accompagner la prime des jeunes conducteurs** (jusqu'à 1 275 € par an) par des contreparties réduisant le risque : franchise plus élevée, conduite accompagnée, boîtier télématique, sans baisse de prime qui créerait de l'antisélection.

Pilotage et suivi annuel

9. **Appliquer le coefficient de tendance** ($\times 1{,}154$ sur la prime pure en 2010) à toute la grille, recalibrer le GLM chaque année avec un effet année, et confirmer la tendance dès la troisième année. *Suivi* : S/P stable entre déciles.
10. **Utiliser la binomiale négative** pour les intervalles de confiance et la simulation (provisionnement, capital, réassurance), la loi de Poisson sous-estimant les polices à 4 sinistres ou plus.
11. **Surveiller individuellement les polices atypiques** : 11 polices, 36 sinistres pour 2,5 attendus. Revue de souscription au cas par cas, mise à jour trimestrielle.