Tarification de l'assurance automobile

Audit, analyse, modélisation et tarification

Morel POUNIGUIA

Présentation de 5 minutes

Données et contrôles

- Portefeuille consolidé : **100 000 polices**
- **87,7 %** des polices sans sinistre sur la période
- Années 2009 et 2010

Anomalies relevées

- Âges de 4 à 250 ans, anciennetés négatives
- 55 doublons stricts, 146 clés répétées
- **12,7 %** de « Housewife » pour des hommes
- Sinistres sans police : **1 011 lignes** (7,6 %), exclues

Nettoyage : 25 décisions documentées, 0,09 % des sinistres retirés.

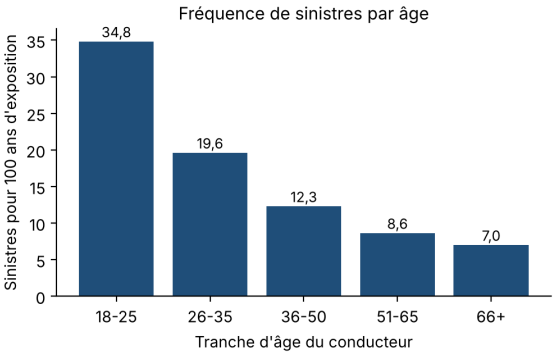
Nombre et montant des sinistres

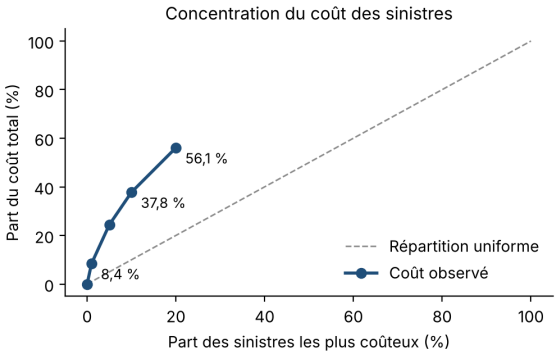
- Surdispersion : variance / moyenne = **1,30**
- Montant moyen 1 174 €, médiane 617 €
- Loi Gamma meilleure que la log-normale

Écarts de prime pure bruts

- Tranche d'âge : $\times$**5,6**
- Occupation : $\times$**4,7**
- Liens faibles pris un à un (V de Cramér de 0,02 à 0,18)

Graphiques : fréquence et concentration





Les 10 % des sinistres les plus chers représentent 37,8 % du coût.

- ACP : 44,5 % de l'information sur deux axes
- Accord k-moyennes / hiérarchique *modéré* (ARI = 0,36)
- Silhouette faible (0,18) : un **continuum de risque**, pas des classes nettes

Profil	Polices (%)	Fréquence (pour 100 ans)
Faible risque	41,1	8,1
Risque élevé	30,4	33,2

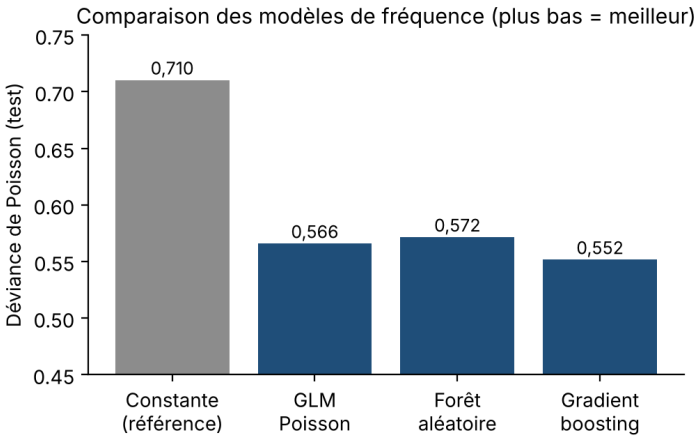
Le profil élevé a une fréquence 4,1 fois supérieure : les profils décrivent, ils ne tarifent pas.

Modélisation de la fréquence

Modèle	Déviance de test	Gain vs constante	Surapprentissage (%)
Constante (référence)	0,710	–	–
GLM de Poisson	0,566	20,3 %	1,4
Gradient boosting de Poisson	**0,552**	**22,3 %**	7,9

- Le GLM obtient plus de 90 % du gain, avec une lecture simple : il sert de base au tarif
- Calibrage : prédit / observé = **1,008** ; indice de Gini = **0,52**
- Coût par sinistre : gain de seulement **4,6 %** ; la tarification repose sur la fréquence

Comparaison des modèles de fréquence



Le gradient boosting gagne 22,3 % sur la référence ; le GLM en obtient plus de 90 %.

Facteurs tarifaires et prévision 2010

Écart de prime (plus cher / moins cher)

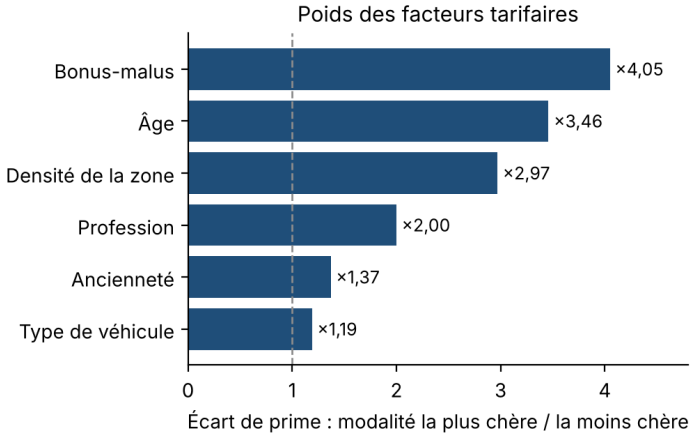
- Bonus-malus : $\times 4{,}05$
- Âge : $\times 3{,}46$
- Densité de la zone : $\times 2{,}97$
- Profession : $\times 2{,}00$

Prévision 2010 avec le tarif 2009

- Coût sous-estimé de **12,4 %**
- Fréquence : 15,6 $\rightarrow$ 17,2 pour 100 ans
- Coefficient de tendance : $\times$**1,154**

Segmentation valable en 2010 : le ratio sinistres/primes reste homogène entre déciles.

Poids des facteurs tarifaires



Bonus-malus et âge sont les facteurs les plus discriminants du tarif.

Recommandations

Avant la mise en production

1. Retrouver les sinistres sans police (7,6 %)
2. Fiabiliser les données à la source
3. Clarifier le codage de la profession

Construction du tarif

- GLM pour le tarif, gradient boosting pour le pilotage
- Ajouter la zone géographique au GLM
- Écrêter les gros sinistres au P99 et réassurer le reste

Pilotage

- Revoir le chargement (30 %) et fixer une prime minimale
- Contreparties pour les jeunes conducteurs
- Coefficient de tendance, recalibrage annuel
- Binomiale négative pour l'incertitude
- Surveiller les 11 polices atypiques

Limites

- **Deux années seulement** : la hausse de 2010 peut être durable ou ponctuelle
- Sinistres sans police et codage de l'occupation : biais possibles
- Avec 100 000 polices, presque tous les tests sont significatifs : la taille des effets compte
- Chargement de 30 % : hypothèse à remplacer par les frais réels